

Wykorzystanie zaawansowanych metod sztucznej inteligencji i uczenia maszynowego w predykcji odpływu klientów (Telco Customer Churn)

Maksymilian Golonko, Piotr Kardyński, Jan Chrzanowski

1 Wybór zbioru

Do realizacji celów badawczych i biznesowych projektu wybrany został zbiór danych **Telco Customer Churn**, udostępniony przez platformę IBM i hostowany w serwisie Kaggle pod adresem: <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>. Zbiór ten zawiera szczegółowe rekordy dotyczące 7043 klientów fikcyjnej firmy telekomunikacyjnej działającej na rynku kalifornijskim, opisując ich zachowania w odniesieniu do 21 unikalnych cech (kolumn).

Wybór tego zestawu danych oparty został na trzech fundamentalnych filarach inżynierii danych i data science:

1. **Wysoka adekwatność biznesowa:** Problem odpływu klientów (ang. *customer churn*) jest jednym z najbardziej krytycznych wyzwań ekonomicznych we współczesnej telekomunikacji. Koszt pozyskania nowego klienta (CAC - *Customer Acquisition Cost*) wielokrotnie przewyższa koszty utrzymania klienta obecnego.
2. **Zróżnicowana i złożona struktura cech:** Dane nie są jednorodne. Zawierają zarówno zmienne ciągłe (np. okres współpracy wyrażony w miesiącach, opłaty miesięczne, łączne koszty), jak i bogatą strukturę zmiennych kategorycznych o charakterze binarnym oraz wieloklasowym (profil demograficzny, typy technologii sieciowej, pakiety bezpieczeństwa, rodzaje kontraktów i metody płatności).
3. **Odpowiednia skala do celów badawczych:** Z punktu widzenia zastosowania metod sztucznej inteligencji, zbiór ten oferuje odpowiednią skalę i złożoność. Liczba ponad siedmiu tysięcy rekordów jest wystarczająca do poprawnego przeprowadzenia procesu uczenia, walidacji oraz testowania modeli bez ryzyka uzyskania wyników przypadkowych.

Dodatkowym atutem zbioru jest naturalne niezbalansowanie klas (wynosi około 1:3), co perfekcyjnie odzwierciedla realia rynkowe i nakłada obowiązek rezygnacji ze zwodniczej metryki *Accuracy* na rzecz optymalizacji zorientowanej na czułość (*Recall*) i miarę F1.


2 Wstępna analiza

Proces Eksploracyjnej Analizy Danych (EDA) został przeprowadzony w oparciu o skrypty zawarte w modułach `baza.py` oraz notatniku `main.ipynb`. Jego celem było określenie kompletności danych, zrozumienie struktur rozkładów oraz wykrycie korelacji między cechami a zmienną celu.

2.1 Czyszczenie i identyfikacja ukrytych braków danych

Wstępne wczytanie danych za pomocą biblioteki `pandas` wykazało obecność 7043 wierszy oraz 21 kolumn. Początkowa inspekcja funkcji `df.isnull().sum()` sugerowała idealną kompletność zbioru (0 brakujących wartości we wszystkich kolumnach). Jednak analiza typu danych kolumny `TotalCharges` ujawniła anomalie – kolumna ta została błędnie zinterpretowana jako typ tekstowy (`object`), mimo iż powinna reprezentować wartości zmiennoprzecinkowe (`float64`).

Przekształcono puste przestrzenie tekstowe na formalne znaczniki braku danych `NaN`. Dalsza analiza logiczna wykazała, że wszystkie te 11 rekordów dotyczyło klientów, dla których zmienna stażu (`tenure`) wynosiła dokładnie 0. Oznacza to, że byli to nowi klienci, którzy dopiero podpisali umowę i nie wygenerowali jeszcze żadnego rachunku. Podjęto decyzję o nieusuwaniu tych wierszy, lecz o zastąpieniu wartości `NaN` wartością numeryczną 0.0, co pozwoliło zachować cenne informacje w pozostałych kolumnach i zapobiegło fałszowaniu statystyk.




Rysunek 1: Wizualizacja przestrzenna braków danych w zbiorze przed zastosowaniem procedury naprawczej.

W celu optymalizacji procesu predykcyjnego z bazy danych bezpowrotnie usunięto kolumnę `customerID`. Jako losowo wygenerowany unikalny klucz tekstowy, zmienna ta charakteryzowała się maksymalną kardynalnością i nie niosła ze sobą żadnej wartości poznawczej ani predykcyjnej dla modeli sztucznej inteligencji, a jej pozostawienie mogłoby prowadzić do przeuczenia modeli na identyfikatorach.

2.2 Rozkład cech i korelacje systemowe


Zmienna docelowa `Churn` została zmapowana na postać binarną (wartość 1 dla klientów odchodzących z firmy, wartość 0 dla klientów pozostających). Analiza rozkładu klas wykazała, że 5174 klientów zdecydowało się pozostać w firmie (73.47%), natomiast 1869 klientów zrezygnowało z usług (26.53%). Świadczy to o silnym niezbalansowaniu zbioru danych, co determinuje konieczność modyfikacji wag klas w algorytmach.



Rysunek 2: Rozkład zmiennej celu oraz gęstość prawdopodobieństwa odejścia klienta w funkcji stażu (`tenure`).

Z wykresu gęstości stażu jasno wynika, że największa rezygnacja występuje w pierwszych miesiącach po podpisaniu umowy. Klienci, którzy przetrwali krytyczny okres adaptacyjny (ok. 12 miesięcy), wykazują skokowo wyższą lojalność, a wskaźnik churnu drastycznie spada dla klientów ze stażem powyżej 60 miesięcy.

Po przeprowadzeniu transformacji zmiennych kategorycznych na postać rzadką metodą kodowania zero-jedynkowego (One-Hot Encoding z usunięciem pierwszej kategorii bazowej w celu uniknięcia pułapki współliniowości), zbiór danych rozrósł się z wyjściowych 21 kolumn do **30 kolumn numerycznych**. Dla tak przygotowanej macierzy obliczono współczynniki korelacji liniowej Pearsona względem zmiennej `Churn`. Do szczegółowej analizy wyselekcjonowano 12 cech o najwyższej wartości bezwzględnej korelacji.



Rysunek 3: Macierz korelacji 12x12 przedstawiająca najsilniejsze liniowe powiązania cech użytkowników z rezygnacją z usług.

Główne wnioski z analizy macierzy korelacji Top 12 przedstawiają się następująco:

- **Typ kontraktu odnawiany co miesiąc (Contract_Month-to-month):** Wykazuje najwyższą dodatnią korelację ze zmienną celu ($r = 0.41$). Potwierdza to perspektywę biznesową – brak długoterminowego zobowiązania prawnego drastycznie ułatwia klientom podjęcie decyzji o natychmiastowym opuszczeniu firmy.
- **Staż klienta (tenure):** Posiada silną korelację ujemną ($r = -0.35$). Dowodzi to, że zbudowanie długotrwałej relacji z konsumentem jest najskuteczniejszą naturalną barierą retencyjną.
- **Technologia światłowodowa (InternetService_Fiber optic):** Wykazuje wyraźną dodatnią korelację z odpływem ($r = 0.31$). Jest to zjawisko nieintuicyjne i bardzo interesujące analitycznie – klienci korzystający z teoretycznie najszybszego i najnowocześniejszego internetu odchodzą częściej, co sygnalizuje potencjalne problemy z ukrytymi kosztami, stabilnością tej technologii lub niedopasowaniem cenowym.

- **Brak usług wsparcia technicznego i bezpieczeństwa (TechSupport_No internet service, OnlineSecurity_No):** Wykazuje istotne powiązania z rezygnacją. Klienci pozbawieni opieki technicznej i systemów bezpieczeństwa rezygnują z dostawcy znacznie szybciej.

3 Definicja problemu i hipotezy badawcze

3.1 Problem biznesowy i analityczny

Zadanie analityczne polega na realizacji **klasyfikacji binarnej**. Głównym celem budowanego modelu jest predykcja, czy dany klient zrezygnuje z usług firmy telekomunikacyjnej (zmienna docelowa Churn przyjmie wartość „Yes”), czy też pozostanie lojalny („No”). Prognoza ta podejmowana jest na podstawie wielowymiarowego profilu klienta, obejmującego cechy demograficzne, parametry finansowe oraz strukturę posiadanych usług.

3.2 Hipoteza główna

Zastosowanie zaawansowanych algorytmów uczenia maszynowego (takich jak Regresja Logistyczna, Lasy Losowe czy XGBoost) pozwoli na zbudowanie modelu klasyfikacyjnego, który z wysoką czułością (*Recall*) oraz precyzją (*Precision*) zidentyfikuje klientów zagrożonych odejściem. Umożliwi to przedsiębiorstwu podjęcie celowanych, proaktywnych działań retencyjnych przed faktycznym formalnym zerwaniem umowy.

3.3 Hipotezy szczegółowe (wynikające z analizy EDA)

Na podstawie przeprowadzonej eksploracyjnej analizy danych (EDA) sformułowano następujące hipotezy szczegółowe:

Typ kontraktu a lojalność: Klienci posiadający umowę krótkoterminową typu „*Month-to-month*” wykazują najwyższą skłonność do migracji. Zmienna ta będzie charakteryzować się jednym z najwyższych współczynników istotności (*feature importance*) w procesie trenowania modeli.

Infrastruktura a jakość usług: Użytkownicy internetu światłowodowego (*Fiber optic*) odchodzą częściej niż użytkownicy korzystający z innych technologii (np. DSL). Sugeruje to ukryty problem z retencją w tym segmencie (wynikający np. z relacji ceny do jakości bądź kwestii technicznych), a model powinien silnie reagować na tę cechę.

Wpływ usług wsparcia: Brak implementacji dodatkowych pakietów niefinansowych, takich jak wsparcie techniczne (*TechSupport*) czy bezpieczeństwo online (*OnlineSecurity*), istotnie zwiększa prawdopodobieństwo rezygnacji klienta z usług firmy.

3.4 Definicja miar sukcesu modelu

Ponieważ nadrzędnym celem biznesowym jest zatrzymanie jak największej liczby klientów przy jednoczesnym kontrolowaniu kosztów akcji marketingowych, kluczową metryką efektywności modelu nie będzie ogólna dokładność (*Accuracy*), lecz następujące wskaźniki:

1. **Czułość (Recall / Sensitivity):** Miara ta definiuje zdolność modelu do wykrywania wszystkich klientów faktycznie odchodzących. Dążymy do zminimalizowania błędów drugiego rodzaju (sytuacji *FN* – *False Negatives*), w których model błędnie uzna, że klient pozostanie lojalny. Matematycznie wyraża się ona wzorem:

$$Recall = \frac{TP}{TP + FN} \quad (1)$$

2. **F1-Score:** Jako średnia harmoniczna precyzji i czułości, wskaźnik ten pozwoli na obiektywną ocenę stabilności i jakości klasyfikatora w warunkach naturalnego dla tego problemu niezbalansowania klas w zbiorze danych (gdzie klasa pozytywna stanowi mniejszość). Średnia harmoniczna nakłada wysoki karę za drastyczny spadek jednej z tych miar:

$$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (2)$$

4 Wybór i opis modeli

Wytypowano cztery zróżnicowane modele klasyfikacyjne. Poniżej przedstawiono ich matematyczno-operacyjny opis, uwzględniający zalety, wady oraz stopień dopasowania do badanego problemu telekomunikacyjnego.

1. Regresja Logistyczna (Logistic Regression):

- *Sposób działania:* Klasyczny model liniowy, który oblicza liniową kombinację cech wejściowych, a następnie przekształca uzyskany wynik za pomocą funkcji logistycznej (sigmoidalnej) w wartość z przedziału $(0, 1)$, interpretowaną jako prawdopodobieństwo przynależności do klasy pozytywnej.
- *Zalety:* Ekstremalnie szybka obliczeniowo, w pełni interpretowalna matematycznie (współczynniki wprost wskazują na iloraz szans - Odds Ratio), posiada wbudowaną prostą obsługę wag klas (`class_weight='balanced'`).
- *Wady:* Zakłada całkowicie liniowe granice decyzyjne, wysoce podatna na współliniowość cech, niezdolna do automatycznego wykrywania interakcji między zmiennymi bez ręcznej inżynierii cech.

- *Dopasowanie do problemu:* **Algorytm ostatecznie nie pasuje do specyfiki badanych danych i został odrzucony na etapie koncepcyjnym.** Struktura zbioru zawiera silnie nieliniowe relacje (szczególnie na płaszczyźnie opłat `MonthlyCharges` i stażu `tenure`). Regresja logistyczna jest zbyt uproszczona, aby bez skomplikowanej i ręcznej inżynierii cech wychwycić te zależności, przez co generowałaby wysoki poziom błędów typu *False Negative*. W projekcie została pominięta w fazie implementacji i posłużyła wyłącznie jako teoretyczny punkt odniesienia (*baseline*) do wykazania przewagi modeli opartych na sztucznej inteligencji.

2. Las Losowy (Random Forest Classifier):

- *Sposób działania:* Algorytm zespołowy oparty na koncepcji baggingu. Buduje niezależnie od siebie dużą liczbę nieskorelowanych drzew decyzyjnych na podpróbkach zbioru treningowego (Bootstrap). Ostateczna decyzja klasyfikacyjna podejmowana jest na drodze demokratycznego głosowania większościowego (Ensemble Voting).
- *Zalety:* Całkowicie odporny na przeuczenie dzięki losowości cech w węzłach, nie wymaga skalowania ani normalizacji zmiennych numerycznych, doskonale obsługuje zmienne typu dummy, natywnie wyznacza stabilną ważność cech. Do walki z asymetrią klas wykorzystuje próbkowanie wewnątrz-drzewiaste (`class_weight='balanced_subsample'`).
- *Wady:* Duże zapotrzebowanie na pamięć operacyjną przy dużej liczbie drzew, brak możliwości sekwencyjnej poprawy błędów.
- *Dopasowanie:* Idealnie dopasowany do mieszanej (numeryczno-kategorycznej) struktury zbioru Telco. Stanowi fundament stabilnej predykcji.

3. XGBoost (Extreme Gradient Boosting):

- *Sposób działania:* Zaawansowana implementacja algorytmu wzmacniania gradientowego (Boosting). Drzewa decyzyjne budowane są sekwencyjnie, jedno po drugim. Każde kolejne drzewo uczy się na błędach (resztach) swoich poprzedników, optymalizując zdefiniowaną funkcję straty za pomocą przybliżenia drugiego rzędu (szereg Taylora) i stosując rygorystyczną regularyzację L1 oraz L2.
- *Zalety:* Najwyższa wydajność predykcyjna dla danych tabelarycznych, wbudowana obsługa brakujących wartości, genialny parametr `scale_pos_weight` do precyzyjnego kontrolowania wagi rzadkiej klasy uciekającej.
- *Wady:* Bardzo wysoka wrażliwość na dobór hiperparametrów, ryzyko szybkiego przeuczenia przy zbyt agresywnym tempie uczenia (`learning_rate`).

- *Dopasowanie*: Główny pretendent do miana najlepszego modelu retencyjnego, pozwalający na precyzyjne wyznaczenie nieliniowych granic decyzyjnych zachowań klientów.

4. Sztuczna Sieć Neuronowa (MLP):

- *Sposób działania*: Model głębokiego uczenia (Deep Learning) zaimplementowany w architekturze PyTorch. Składa się z warstwy wejściowej (30 neuronów), sekwencji warstw ukrytych z nieliniowymi funkcjami aktywacji (np. ReLU) oraz warstwy wyjściowej z aktywacją sigmoidalną. Model uczy się poprzez propagację wsteczną błędów (Backpropagation) przy użyciu optymalizatora gradientowego Adam i funkcji straty Binary Cross-Entropy (BCE).
- *Zalety*: Zdolność do aproksymacji dowolnych, nawet najbardziej skomplikowanych funkcji matematycznych, automatyczne wyodrębnianie interakcji wyższego rzędu między odległymi cechami.
- *Wady*: Wymaga bezwzględnego skalowania danych (`StandardScaler`), skrajnie podatna na przeuczenie na małych zbiorach danych, wymaga ręcznego projektowania architektury (liczba neuronów, warstw, współczynnik Dropout), działa na zasadzie całkowitej "czarnej skrzynki" (brak prostej interpretowalności cech).
- *Dopasowanie*: Wybrana jako ambitny benchmark technologiczny, mający zweryfikować efektywność sieci neuronowych w starciu z klasycznymi modelami dedykowanymi dla struktur tabelarycznych.

5 Implementacja modeli

Zbiór danych przed procesem uczenia został losowo podzielony na podzbiór treningowy (80% - 5634 rekordy) oraz testowy (20% - 1409 rekordów). Zastosowano próbkowanie warstwowe (`stratify=y`), co zagwarantowało identyczny rozkład zmiennej celu (26.5% churnu) w obu zestawach i zapobiegło zafałszowaniu wyników testowych.

5.1 Implementacja modelu Lasu Losowego

W celu maksymalizacji metryki czułości przeprowadzono pełne przeszukiwanie siatki z 3-krotną walidacją krzyżową (`GridSearchCV(..., scoring='recall')`). Poniższy listing przedstawia przestrzeń przeszukiwania parametrów:

```
param_grid_rf = {
    'n_estimators': [100, 200],
    'max_depth': [5, 10, 15],
    'min_samples_split': [2, 5, 10],
```


```
'min_samples_leaf': [1, 2, 4]
}
```

Proces optymalizacji wyłonił następującą najlepszą konfigurację hiperparametrów: {'max_depth': 5, 'min_samples_leaf': 2, 'min_samples_split': 10, 'n_estimators': 100}. Zastosowanie relatywnie płytkich drzew (max_depth=5) zadziałało jako silna naturalna regularyzacja, zapobiegając przeuczeniu modelu na szumie informacyjnym.

Po uruchomieniu zoptymalizowanego modelu na zbiorze testowym uzyskano następujący raport klasyfikacji (*Classification Report*):

Tabela metryk klasyfikacji (Classification Report) - Las Losowy:

	precision	recall	f1-score	support
0	0.92	0.71	0.80	1035
1	0.51	0.82	0.62	374
accuracy			0.74	1409
macro avg	0.71	0.76	0.71	1409
weighted avg	0.81	0.74	0.75	1409



Rysunek 4: Macierz pomyłek oraz profil ważności cech dla zoptymalizowanego algorytmu Random Forest.

Model poprawnie zidentyfikował 307 z 374 klientów odchodzących, generując czułość na poziomie **82%**. Niska precyzja dla klasy pozytywnej (51%) oznacza obecność fałszywych alarmów, co jest w pełni akceptowalne w przyjętej strategii biznesowej.

5.2 Implementacja modelu XGBoost

Współczynnik `scale_pos_weight` został ustawiony automatycznie na wartość 2.76 (stosunek klasy 0 do klasy 1), co drastycznie zwiększyło karę za błędne zaklasyfikowanie rezygnującego klienta. Przestrzeń poddana optymalizacji wyglądała następująco:


```
param_grid_xgb = {  
    'n_estimators': [100, 200],  
    'max_depth': [3, 4, 5],  
    'learning_rate': [0.01, 0.05, 0.1],  
    'subsample': [0.8, 1.0]  
}
```

Najlepsza kombinacja parametrów zwrócona przez GridSearch to: {'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 200, 'subsample': 1.0}. Ponownie algorytm postawił na bardzo proste, płytke struktury drzew bazowych (`max_depth=3`) połączone z niskim krokiem uczenia, co gwarantuje doskonałą generalizację.

Wyniki testowe dla zoptymalizowanego modelu XGBoost prezentują się następująco:

Tabela metryk klasyfikacji (Classification Report) - XGBoost:

	precision	recall	f1-score	support
0	0.91	0.70	0.79	1035
1	0.50	0.81	0.62	374
accuracy			0.73	1409
macro avg	0.70	0.75	0.71	1409
weighted avg	0.80	0.73	0.75	1409



Rysunek 5: Macierz pomyłek oraz struktura ważności cech dla zoptymalizowanego modelu XGBoost.

Wykresy istotności cech dla obu modeli drzewiastych zgodnie wskazały, że dwoma najważniejszymi predyktorami odpływu są `tenure` oraz `Contract_Month-to-month`.

5.3 Implementacja i wyniki Wielowarstwowej Sieci Neuronowej (MLP)

Analiza pierwszych przebiegów wykazała, że złożona architektura sieci drastycznie szybko ulegała zjawisku przeuczenia (overfittingu) na zbiorze treningowym. Z tego powodu w fazie optymalizacji zdecydowano się na uproszczenie struktury modelu. Ostateczna, zoptymalizowana sieć składała się z warstwy wejściowej (obsługującej 30 zakodowanych cech), zaledwie jednej warstwy ukrytej (32 neurony z funkcją aktywacji ReLU oraz agresywnym odrzucaniem neuronów `Dropout(0.4)`) oraz warstwy wyjściowej z pojedynczym neuro-nem. Aby obsłużyć problem niezbalansowania klas, do funkcji straty `BCEWithLogitsLoss` wprowadzono tensor wag (wartość 2.89 dla klasy mniejszościowej), a warstwa wyjściowa zwracała surowe logity.

Wszystkie zmienne wejściowe poddano standaryzacji (`StandardScaler`). Zoptymalizowany proces uczenia skrócono do 15 epok, z rozmiarem paczki (*batch size*) równym 64 oraz zmniejszonym współczynnikiem uczenia $lr = 0.001$ przy wykorzystaniu optymalizatora `Adam`. Poniżej przedstawiono metryki klasyfikacji dla modelu po procesie tuningu:


Tabela 1: Tabela metryk klasyfikacji (Classification Report) – Zoptymalizowana Sieć Neuronowa MLP

GENEROWANIE RAPORTU KLASYFIKACJI...

Weryfikacja długości - Prawdziwe etykiety: 1409, Przewidywania: 1409

RAPORT KLASYFIKACJI (Classification Report) dla modelu zoptymalizowanego:

	precision	recall	f1-score	support
Zostaje (No)	0.83	0.89	0.86	1035
Odchodzi (Yes)	0.63	0.51	0.56	374
accuracy			0.79	1409
macro avg	0.73	0.70	0.71	1409
weighted avg	0.78	0.79	0.78	1409



Rysunek 6: Krzywa zbieżności funkcji straty oraz końcowa macierz pomyłek dla zoptymalizowanego modelu głębokiej sieci neuronowej MLP.

Wyniki jednoznacznie potwierdzają teoretyczne przypuszczenia projektu. Próba zbalansowania sieci poprzez wagi klas pozwoliła na nieznaczne podniesienie czułości (*Recall*) do poziomu **51%**, jednak odbyło się to kosztem kompromisu i precyzja dla uciekających klientów osiągnęła wartość zaledwie **63%**. Model MLP wykazuje znaczną niestabilność na tym konkretnym zbiorze danych: albo całkowicie ignoruje odchodzących klientów próbując maksymalizować ogólną celność, albo po zmianie wag generuje znaczny odsetek fałszywych alarmów. Udowadnia to empirycznie, że na średnich, tabelarycznych zbiorach o dominującej strukturze kategoriowej, architektury głębokiego uczenia są zdecydowanie mniej wydajne biznesowo niż algorytmy oparte na zespołach drzew (takie jak XGBoost

czy Random Forest).

6 Część porównawcza

W celu dokonania jednoznacznej i obiektywnej oceny, w poniższej tabeli zestawiono wyniki wszystkich zaimplementowanych i przetestowanych modeli sztucznej inteligencji pod kątem kluczowych metryk statystycznych dla klasy pozytywnej ($\text{Churn} = 1$).

Tabela 2: Zestawienie zbiorcze metryk efektywności modeli klasyfikacyjnych (klasa 1)

Model Klasyfikacyjny	Accuracy	Precision	Recall (Czułość)	F1-Score
Las Losowy (RF)	0.74	0.51	0.82	0.62
XGBoost	0.73	0.50	0.81	0.62
Sieć Neuronowa MLP (PyTorch)	0.79	0.63	0.51	0.56

Szczegółowa analiza porównawcza pozwala na wyciągnięcie następujących wniosków naukowych i technicznych:

- Dominacja modeli opartych na baggingu w optymalizacji czułości:** Najwyższą czułość (82%) oraz najwyższy wskaźnik zbalansowany F1-Score (0.62) zanotował model Lasu Losowego. Co prawda sieć MLP osiągnęła najwyższą ogólną dokładność ($\text{Accuracy} = 79\%$), jednak w przypadku asymetrycznego problemu biznesowego jest to metryka zwodnicza, maskująca krytycznie słabą detekcję odchodzących klientów. Równoległe uśrednianie wyników z niezależnych drzew w Lesie Losowym okazało się najskuteczniejsze z punktu widzenia nadrzędnego celu projektu.
- Porównanie XGBoost vs Random Forest:** Model XGBoost uzyskał wyniki niemal identyczne ($\text{Recall} 81\%$, $\text{F1-Score} 0.62$). Różnica 1% na korzyść Lasu Losowego w metryce Recall wynika z faktu, że Random Forest jest naturalnie bardziej odporny na specyficzny szum w danych kategorycznych i nie ulega lokalnym minimom tak mocno, jak algorytmy gradientowe przy małej liczbie głębokich interakcji.
- Niska efektywność biznesowa sieci neuronowej MLP:** Sieć neuronowa MLP, pomimo zaawansowanej architektury, osiągnęła drastycznie niską czułość (zaledwie 51%). Model ten poświęcił zdolność wykrywania uciekających klientów na rzecz wyższej precyzji i ogólnej celności w klasie dominującej. Testy modelu MLP potwierdziły również, że taki model źle sobie radzi na małej ilości danych.
- Interpretacja biznesowa asymetrii precyzji i czułości:** Modele drzewiaste wykazują relatywnie niską precyzję (ok. 50-51%). Oznacza to, że na dwóch klientów wskazanych przez model jako "zagrożeni odpływem", jeden w rzeczywistości nie

zamierzał odchodzić. W kontekście problemu churnu nie jest to jednak wadą, a świadomym kompromisem. Koszt prewencyjnej akcji marketingowej (np. przyznanie rabatu 10%) dla klienta lojalnego jest znikomy w porównaniu z gigantycznym kosztem całkowitej utraty klienta, którego system by przeoczył (co miałoby miejsce przy zastosowaniu sieci MLP z jej 51-procentowym recall'em).

7 Część z wnioskami

Realizacja pełnego procesu analityczno-implementacyjnego dla zbioru Telco Customer Churn pozwoliła na sformułowanie kluczowych wniosków końcowych:

1. **Potwierdzenie hipotezy głównej:** Główna hipoteza badawcza została w pełni potwierdzona. Zoptymalizowany model Lasu Losowego przekroczył zakładany próg czułości, osiągając wynik 82%. System potrafi bezbłędnie wytypować ponad 4 na 5 klientów zamierzających faktycznie zerwać współpracę z firmą telekomunikacyjną.
2. **Weryfikacja hipotez szczegółowych:**
 - Hipoteza o dominacji algorytmów nieliniowych opartych na zespołach drzew decyzyjnych (Random Forest, XGBoost) znalazła pełne odzwierciedlenie w najwyższych miarach F1-Score (0.62) oraz czułości rzędu 81-82%.
 - Hipoteza dotycząca kluczowych cech została zwalidowana przez wykresy istotności (Feature Importance) – typ kontraktu *Month-to-month* oraz staż *tenure* stanowią główne osie decyzyjne procesów rezygnacji.
 - Hipoteza o słabości modeli głębokich na małych strukturach tabelarycznych znalazła bezpośrednie potwierdzenie w najniższej czułości zoptymalizowanej sieci MLP (zaledwie 51%).
3. **Rekomendacja wdrożeniowa:** Na podstawie uzyskanych wyników empirycznych zespół projektowy jednoznacznie rekomenduje wdrożenie modelu **Lasu Losowego (Random Forest)**. Charakteryzuje się on najwyższą stabilnością biznesową, generuje najwyższy zwrot z inwestycji (ROI) poprzez zablokowanie odejść (najwyższy Recall) oraz, w przeciwieństwie do sieci neuronowej, nie wymaga kosztownego i skomplikowanego obliczeniowo preprocessingu (np. skalowania cech numerycznych).